

Учебник по Эконометрике

Лекция 4: Моделирование зависимости

Джон Стачурски

Лекции: Акшай Шенкер

Перевел: Алексей Кедо

1 октября 2020 г.

Случайный вектор

Случайный вектор \mathbf{x} в \mathbb{R}^N — это функция из Ω в \mathbb{R}^N со следующим свойством

$$\{\omega \in \Omega : \mathbf{x}(\omega) \in B\} \in \mathcal{F} \quad \text{для всех } B \in \mathcal{B}(\mathbb{R}^N)$$

Мы можем также определить **случайный вектор** \mathbf{x} в \mathbb{R}^N как список из N случайных переменных (x_1, \dots, x_N)

3/106

Вектор (y_1, \dots, y_N) который сообщает результат этой выборки, можно рассматривать как случайный вектор в \mathbb{R}^N

8/106

1. $\text{var}[\mathbf{x}]$ существует и неотрицательно определена,
2. $\text{var}[\mathbf{x}] = \mathbb{E}[\mathbf{x}\mathbf{x}^T] - \boldsymbol{\mu}\boldsymbol{\mu}^T$, и
3. $\text{var}[\mathbf{A}\mathbf{x} + \mathbf{b}] = \mathbf{A} \text{var}[\mathbf{x}] \mathbf{A}^T$ (для любых постоянных и согласованных \mathbf{A}, \mathbf{b}).

Кросс-ковариация между случайными векторами \mathbf{x} и \mathbf{y} определяется как

$$\text{cov}[\mathbf{x}, \mathbf{y}] := \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^T]$$

Очевидно, $\text{var}[\mathbf{x}] = \text{cov}[\mathbf{x}, \mathbf{x}]$

Факт. (??) Если \mathbf{z} — случайный вектор в \mathbb{R}^N , удовлетворяющий $\mathbb{E}[\mathbf{z}\mathbf{z}^T] = \mathbf{I}$ и \mathbf{A} любая постоянная матрица размера $N \times N$, то

$$\mathbb{E}[\mathbf{z}^T \mathbf{A} \mathbf{z}] = \text{trace } \mathbf{A}$$

Доказательство — решенное упражнение (смотрите упр. ??)

Совместные распределения

Распределение или **закон** P в \mathbb{R}^N — вероятностная мера Борелевских множеств $\mathcal{B}(\mathbb{R}^N)$

По определению, оно удовлетворяет $P(\mathbb{R}^N) = 1$ и $P(\cup_{n=1}^{\infty} B_n) = \sum_{n=1}^{\infty} P(B_n)$ для любых непересекающихся последовательностей $\{B_n\}$ в $\mathcal{B}(\mathbb{R}^N)$




Рис.: Пример распределения и события A и B

Любое распределение P в \mathbb{R}^N характеризуется функцией

$$F(\mathbf{s}) := F(s_1, \dots, s_N) := P\left(\times_{n=1}^N (-\infty, s_n]\right) \quad (\mathbf{s} \in \mathbb{R}^N)$$

Функция F — **функция совместного распределения**, которая является функцией $F: \mathbb{R}^N \rightarrow [0, 1]$ со следующими свойствами

1. непрерывна справа по каждому из своих аргументов,
2. возрастает по каждому из своих аргументов, и
3. удовлетворяет

$$F(\mathbf{s}_j) \rightarrow 1 \text{ при } s_j \rightarrow \infty$$

$$\text{и } F(s_1, \dots, s_{nj}, \dots, s_N) \rightarrow 0 \text{ при } s_{nj} \rightarrow -\infty$$

Распределение P в \mathbb{R}^N :

- **дискретно**, если P имеет носитель распределения в счетном подпространстве \mathbb{R}^N
- **абсолютно непрерывно**, если $P(B) = 0$ всюду, где B имеет меру Лебега равную нулю

Опять же, абсолютная непрерывность необходима и достаточна для существования функции плотности:

$$P(B) = \int_B p(\mathbf{s}) \, d\mathbf{s} \quad \text{для всех } B \in \mathcal{B}(\mathbb{R}^N)$$

справа — многомерный интеграл, который мы можем записать как

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \mathbb{1}_B(s_1, \dots, s_N) p(s_1, \dots, s_N) \, ds_1 \cdots ds_N$$

Если p — любая функция плотности в \mathbb{R}^N , то вышенаписанное определяет распределение

Пример. Многомерное нормальное распределение или многомерное распределение Гаусса в \mathbb{R}^N — функция p вида

$$p(\mathbf{s}) = (2\pi)^{-N/2} \det(\mathbf{\Sigma})^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{s} - \boldsymbol{\mu})^T \mathbf{\Sigma}^{-1} (\mathbf{s} - \boldsymbol{\mu}) \right\}$$

где $\boldsymbol{\mu}$ — любой вектор размера $N \times 1$ и $\mathbf{\Sigma}$ — положительно определенная матрица размера $N \times N$

Представим это распределение как $N(\boldsymbol{\mu}, \mathbf{\Sigma})$

Случай $N(\mathbf{0}, \mathbf{I})$ называется **многомерным стандартным нормальным распределением**




Рис.: Функция плотности двумерного стандартного нормального распределения

Распределение произведения P_1, \dots, P_N определяется следующим фактом:

Факт. (??) Возьмем распределения P_1, \dots, P_N в \mathbb{R} , существует единственное и определенное распределение \mathring{P} в \mathbb{R}^N , такое что

$$\mathring{P}(B_1 \times \dots \times B_N)$$

$$= \prod_{n=1}^N P_n(B_n) \quad \text{для всех } B_n \in \mathcal{B}(\mathbb{R}), n = 1, \dots, N$$

Единственное, потому что распределения однозначно закреплены цилиндрическими множествами \mathbb{R}^N (смотрите страницу 128 в ЕТ)

Возьмем любое распределение P в \mathbb{R}^N , n -ое **частное распределение** P — это распределение в \mathbb{R} определенное как

$$P_n(B) = P(\mathbb{R} \times \cdots \times \mathbb{R} \times B \times \mathbb{R} \times \cdots \times \mathbb{R})$$

Здесь B — n -ый элемент Декартового произведения

Эквивалентно,

$$P_n(B) = P\{\mathbf{s} \in \mathbb{R}^N : \mathbf{s}^\top \mathbf{e}_n \in B\}$$

Из P_n мы можем также получить **частную функцию распределения** F_n с помощью

$$F_n(s) := P_n((-\infty, s]) \quad (s \in \mathbb{R})$$

(смотрите страницу ?? в ЕТ)

Если P_n абсолютно непрерывная, она имеет функцию плотности p_n

Если совместное распределение P имеет функцию плотности p , частное распределение P_n имеет функцию плотности p_n – “интегрировать по другим переменным”

Например, двумерный случай:

$$p_1(s_1) = \int_{-\infty}^{\infty} p(s_1, s_2) \, ds_2$$




Рис.: Двумерная совместная функция плотности и две ее частных вариации

Совместное распределение не может быть получено только из частных

- частные не говорят нам о своем взаимодействии

Исключение составляют случаи отсутствия взаимодействия - случай произведения функций распределения

Распределения случайных векторов

Пусть \mathbf{x} — случайный вектор в \mathbb{R}^N

Распределение x является вероятностной мерой P на $\mathcal{B}(\mathbb{R}^N)$ определяемая как

$$P(B) = \mathbb{P}\{\mathbf{x} \in B\} \quad (B \in \mathcal{B}(\mathbb{R}^N))$$

P здесь также называется **совместным распределением** x_1, \dots, x_N , и мы пишем $\mathcal{L}(\mathbf{x}) = P$

или, в векторной форме

$$F(s_1, \dots, s_N) = \mathbb{P}\{x_1 \leq s_1, \dots, x_N \leq s_N\}$$

$$F(\mathbf{s}) = \mathbb{P}\{\mathbf{x} \leq \mathbf{s}\} \quad (\mathbf{s} \in \mathbb{R}^N)$$

26/106

Мы пишем $\mathcal{L}(x) = N(\mu, \sigma)$

Случайный вектор x в \mathbb{R}^N **многомерный нормальный**, если

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{C}\mathbf{z}$$

где \mathbf{z} — стандартный нормальный случайный вектор размера $K \times 1$, матрица \mathbf{C} имеет размер $N \times K$ и вектор $\boldsymbol{\mu}$ имеет размер $N \times 1$

Если x многомерный нормальный, то мы пишем

$$\mathcal{L}(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \text{ где}$$

$$\mu := \mathbb{E} \mathbf{x} \quad \text{и} \quad \Sigma := \text{var } \mathbf{x}$$

Имеется $\Sigma = \mathbf{C}\mathbf{C}^T$ (вспомним факт 5.1.2 в ЕТ)

$\mathcal{L}(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ не подразумевает, что \mathbf{x} имеет многомерную нормальную функцию плотности

- распределение x может и не быть абсолютно непрерывным, например если $C = 0$

Абсолютная непрерывность распределения \mathbf{x} совпадает с условиями, где $\Sigma := \text{var } \mathbf{x}$ несингулярна – несингулярность Σ будет верна тогда и только тогда, когда \mathbf{C}^T имеет полный ранг столбцов

Факт. (??) Пусть x — случайный вектор в \mathbb{R}^N . Следующие утверждения верны:

1. вектор \mathbf{x} многомерный нормальный тогда и только тогда, когда $\mathbf{a}^T \mathbf{x}$ нормально распределено в \mathbb{R} для каждого постоянного вектора \mathbf{a} размера $N \times 1$
2. Если $\mathcal{L}(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, то

$$\mathcal{L}(\mathbf{Ax} + \mathbf{b}) = \mathcal{N}(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top)$$

для всех постоянных согласованных \mathbf{A}, \mathbf{b}

Всегда ли совместное распределение N одномерных нормальных случайных величин является многомерным нормальным?

- Ответ: нет

35/106

37/106

$$F(s_1, \dots, s_N) = \prod_{n=1}^N F_n(s_n)$$

для всех $(s_1, \dots, s_N) \in \mathbb{R}^N$, где F функция распределения x и F_1, \dots, F_N частные функции распределения (почему?)

39/106

Пример.

Пусть $\mathcal{L}(\mathbf{x}) = \mathcal{L}(x_1, \dots, x_N) = N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$

Предположим также, что Σ диагональна, с n -ым диагональным элементом $\sigma_n > 0$, тогда x_1, \dots, x_N независимые

Чтобы убедиться в этом, проверим для любых $\mathbf{s} = (s_1, \dots, s_N) \in \mathbb{R}^N$, имеется

$$\begin{aligned} p(\mathbf{s}) &= (2\pi)^{-N/2} \det(\boldsymbol{\Sigma})^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{s} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{s} - \boldsymbol{\mu}) \right\} \\ &= \frac{1}{(2\pi)^{N/2} \prod_{n=1}^N \sigma_n} \exp \left\{ -\frac{1}{2} \sum_{n=1}^N (s_n - \mu_n)^2 \sigma_n^{-2} \right\} \end{aligned}$$

Последнее выражение можно разложить дальше

$$p(\mathbf{s}) = \prod_{n=1}^N \frac{1}{(2\pi)^{1/2}\sigma_n} \exp \left\{ \frac{-(s_n - \mu_n)^2}{2\sigma_n^2} \right\} = \prod_{n=1}^N p_n(s_n)$$

где p_n — функция плотности $N(\mu_n, \sigma_n^2)$

Факт. (??) Если x_1, \dots, x_N независимые и каждый x_n интегрируемый, то

$$\mathbb{E} \left[\prod_{n=1}^N x_n \right] = \prod_{n=1}^N \mathbb{E} [x_n]$$

Доказательство. Заметим, что $f_n(\mathbf{x}_n) \in B_n$ тогда и только тогда, когда $\mathbf{x}_n \in f^{-1}(B_n)$. Это ведет к

$$\bigcap_{n=1}^N \{f_n(\mathbf{x}_n) \in B_n\} = \bigcap_{n=1}^N \{\mathbf{x}_n \in f^{-1}(B_n)\}$$

Применяем независимость x_1, \dots, x_N

$$\mathbb{P} \bigcap_{n=1}^N \{f_n(\mathbf{x}_n) \in B_n\}$$

$$= \prod_{n=1}^N \mathbb{P}\{\mathbf{x}_n \in f^{-1}(B_n)\} = \prod_{n=1}^N \mathbb{P}\{f_n(\mathbf{x}_n) \in B_n\}$$

Обратное не верно: можно найти примеры зависимых векторов с нулевой ковариацией. Однако,

Факт. (??) Если \mathbf{x} многомерно нормально распределен и \mathbf{A} и \mathbf{B} согласованные постоянные матрицы, то \mathbf{Ax} и \mathbf{Bx} независимые тогда и только тогда, когда $\text{cov}(\mathbf{Ax}, \mathbf{Bx}) = \mathbf{0}$

Факт. (??) Пусть S — любое линейное подпространство \mathbb{R}^N , $\mathbf{P} := \text{proj } S$ и \mathbf{M} — остаточная проекция. Если $\mathcal{L}(\mathbf{z}) = \mathbf{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ в \mathbb{R}^N для некоторых $\sigma^2 > 0$, то $\mathbf{P}\mathbf{z}$ и $\mathbf{M}\mathbf{z}$ независимые

Факт. (??) Если w_1, \dots, w_N независимые с $\mathcal{L}(w_n) = N(\mu_n, \sigma_n^2)$ для всех n , то

$$\mathcal{L} \left[\alpha_0 + \sum_{n=1}^N \alpha_n w_n \right] = N \left(\alpha_0 + \sum_{n=1}^N \alpha_n \mu_n, \sum_{n=1}^N \alpha_n^2 \sigma_n^2 \right)$$

Суммы произвольных нормальных не всегда нормальны — нам требуется многомерное нормальное распределение

В факте (??) выше:

$$\mathcal{L}(w_1, \dots, w_N) = N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

где $\mathbf{e}_n^T \boldsymbol{\mu} = \mu_n$, и

$$\boldsymbol{\Sigma} = \text{diag}(\sigma_1^2, \dots, \sigma_N^2)$$

Копула C в \mathbb{R}^N — многомерная функция распределения определённая на единичном гиперкубе $[0, 1]^N$, такая что каждое ее частное распределение равномерно на $[0, 1]$

C — функция вида

$$C(s_1, \dots, s_N) = \mathbb{P}\{u_1 \leq s_1, \dots, u_N \leq s_N\} \quad (5)$$

Где $0 \leq s_n \leq 1$ и $\mathcal{L}(u_n) = U[0, 1]$ для всех n

Пока каждый u_n имеет фиксированное частное распределение, существует бесконечно много способов составить совместное распределение

Пример. Функция $C(s_1, s_2) = s_1 s_2$ on $[0, 1]^2$ называется
независимая копула

Частные распределения $C(s_1, 1) = s_1$ и $C(1, s_2) = s_2$ как и
требуется

(Это функции распределения для $U[0, 1]$ распределения)

Пример. Копула Гумбеля — класс функций в $[0, 1]^2$, определяемый как

$$C(s_1, s_2) = \exp \left\{ - \left[(-\ln s_1)^\theta + (-\ln s_2)^\theta \right]^{1/\theta} \right\}, \quad (\theta \geq 1)$$

Копула Клейтона определяется как

$$C(s_1, s_2) = \left\{ \max \left[s_1^{-\theta} + s_2^{-\theta} - 1, 0 \right] \right\}^{-1/\theta}, \quad (\theta \geq -1, \theta \neq 0)$$

Обе они принадлежат к общему классу, называемому **Архимедовы копулы**

Мы можем взять равномерные функции распределения F_1, \dots, F_N и копулу C , чтобы создать многомерную функцию распределения в \mathbb{R}^N с помощью

$$F(s_1, \dots, s_N) = C(F_1(s_1), \dots, F_N(s_N))$$

$$(s_n \in \mathbb{R}, n = 1, \dots, N) \quad (6)$$

Польза: разделяем определение частных и определение совместного распределения

Пример. **bonhomme2009assessing** использует копулы для моделирования одного компонента динамики заработка в исследовании, основанном на трехлетних панельных данных (French Labor Force Survey)

Разделы относительно большие (около 30 000), что позволяет гибко моделировать частные распределения с помощью смеси нормальных

Однако, размер временного ряда короткий, поэтому используется семейство копул с одним параметром для привязки частных во времени не трудозатратным способом

Теорема. (??) Если F — некоторая функция распределения в \mathbb{R}^N с частными F_1, \dots, F_N , то существует копула C , такая что (6) выполняется. Если каждый F_n непрерывен, то это представление является единственным.

Если F_1, \dots, F_N равномерные нормальные, то $C(F_1(s_1), \dots, F_N(s_N))$ будут равняться многомерной нормальной функции распределения для одного варианта копулы, называемой Гауссовой копулой

Другие варианты приводят к другим распределениям

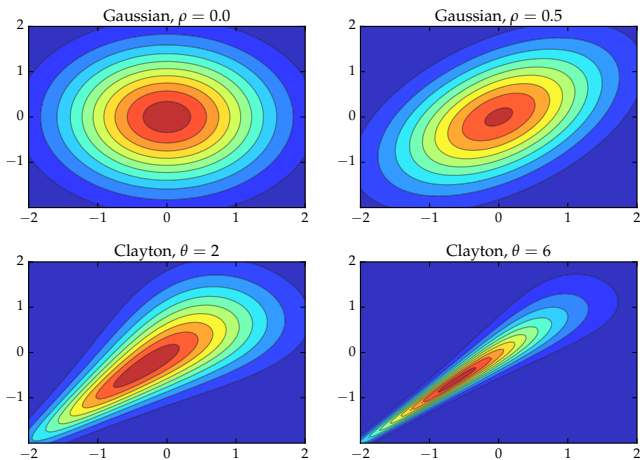


Рис.: Двумерный Гауссовская (вверху) и не-Гауссовская (внизу)

Свойства именных распределений

Факт. (??) Если x_1, \dots, x_N независимые и $\mathcal{L}(x_n) = \chi^2(k_n)$, то $\mathcal{L}(\sum_n x_n) = \chi^2(\sum_n k_n)$

Факт. (??) Если z и x независимые с $\mathcal{L}(z) = N(0, 1)$ и $\mathcal{L}(x) = \chi^2(k)$, то

$z\sqrt{\frac{k}{x}}$ распределено как t с k степенями свободы

Факт. (??) Если $\mathcal{L}(z_1, \dots, z_N) = N(\mathbf{0}, \mathbf{I})$, то $\mathcal{L}(\sum_{n=1}^N z_n^2) = \chi^2(N)$.

Факт. (??) Если $\mathcal{L}(\mathbf{z}) = N(\mathbf{0}, \mathbf{I})$ и \mathbf{A} симметрична и идемпотентна, то

$$\mathcal{L}(\mathbf{z}^T \mathbf{A} \mathbf{z}) = \chi^2(K) \quad , \text{ где } K := \text{trace } \mathbf{A}$$

Упражнение: получите факт (??) из факта (??). (Смотрите страницу ?? в ЕТ)

Условия и ожидание

Условное ожидание — одно из важнейших понятий как в экономической теории, так и в эконометрике

В этом разделе дается построение математического ожидания, основанное на проекции:

- условное математическое ожидание как оптимальное предсказание с учетом ограниченной информации

Условные функции плотности

Сначала обсуждение условных функций плотности

Пусть x_1 и x_2 — случайные величины. **Условная функция плотности** x_2 при заданном $x_1 = s_1$ определяется как

$$p(s_2 | s_1) := \frac{p(s_1, s_2)}{p(s_2)}$$

Здесь p может обозначать совместную, частную или условную функцию плотности, определяемую аргументом

Закон полной вероятности расширяется до случая с функциями плотности следующим образом: Если (x_1, x_2) — случайный вектор в \mathbb{R}^2 , то

$$p(s_2) = \int_{-\infty}^{\infty} p(s_2 | s_1) p(s_1) ds_1 \quad (s_2 \in \mathbb{R})$$

Доказательство. Зафиксируем $s_2 \in \mathbb{R}$ и проинтегрируем совместную функцию плотности, чтобы получить частную, получается

$$p(s_2) = \int_{-\infty}^{\infty} p(s_1, s_2) ds_1$$

Сочетаем с $p(s_2 | s_1) = p(s_1, s_2) / p(s_1)$, чтобы получить результат

Закон Байеса также расширяется до случая с функциями плотности:

$$p(s_2 | s_1) = \frac{p(s_1 | s_2)p(s_2)}{p(s_1)}$$

Условная функция плотности x_{k+1}, \dots, x_N при $x_1 = s_1, \dots, x_k = s_k$ определяется как

$$p(s_{k+1}, \dots, s_N | s_1, \dots, s_k) = \frac{p(s_1, \dots, s_N)}{p(s_1, \dots, s_k)}$$

Перегруппируйте, чтобы получить полезное разложение совместной функции плотности:

$$p(s_1, \dots, s_N) = p(s_{k+1}, \dots, s_N | s_1, \dots, s_k) p(s_1, \dots, s_k)$$

Предположим, мы хотим предсказать случайную переменную y с помощью другой переменной x

Возьмем x такой, что x и y , как ожидается, будут близки при большинстве реализаций неопределенности

Но что значит "ожидаются близкими"?

Среднеквадратическая ошибка (MSE)

$$\mathbb{E}[(x - y)^2]$$

Среднеквадратическое отклонение:

$$\|x - y\| := \sqrt{\mathbb{E}[(x - y)^2]} \quad (7)$$

Есть много параллелей между обычным векторным пространством с евклидовой нормой и множеством случайных величин в сочетании с "нормой", определенной в (7) — мы формализуем эти идеи далее

Первым геометрическим понятием, которое мы определили для векторов, было скалярное произведение

Аналогично, определим **скалярное произведение между двумя случайными величинами** x и y

$$\langle x, y \rangle := \mathbb{E}[xy]$$

Неравенство Коши — Буняковского для случайных величин говорит нам, что $\mathbb{E}[xy]$ должен быть конечным и определенным всюду, где x и y оба имеют конечные вторые моменты

Множество случайных величин с конечными вторыми моментами обычно обозначается как L_2

$$L_2 := \{ \text{все случайные величины } x \text{ в } (\Omega, \mathcal{F}, \mathbb{P}) \text{ с } \mathbb{E}[x^2] < \infty \}$$

Факт. (??) Для любых $\alpha, \beta \in \mathbb{R}$ и любых $x, y, z \in L_2$ следующие утверждения верны:

1. $\langle x, y \rangle = \langle y, x \rangle$.
2. $\langle \alpha x, \beta y \rangle = \alpha \beta \langle x, y \rangle$.
3. $\langle x, \alpha y + \beta z \rangle = \alpha \langle x, y \rangle + \beta \langle x, z \rangle$.

Свойства следуют из определения скалярного произведения и линейности \mathbb{E}

Сравните приведенное выше с фактом ?? в ЕТ для векторов в евклидовом пространстве

Определим L_2 норму как

$$\|x\| := \sqrt{\langle x, x \rangle} := \sqrt{\mathbb{E}[x^2]} \quad (x \in L_2)$$

Норма дает понятие расстояния $\|x - y\|$ между случайными величинами что согласуется с понятием среднеквадратического отклонения

Факт. (??) Для любых $\alpha \in \mathbb{R}$ и любых $x, y \in L_2$, следующие утверждения верные:

1. $\|x\| \geq 0$ и $\|x\| = 0$ тогда и только тогда, когда $x = 0$
2. $\|\alpha x\| = |\alpha| \|x\|$
3. $\|x + y\| \leq \|x\| + \|y\|$
4. $|\langle x, y \rangle| \leq \|x\| \|y\|$

Свойство 2. приведенного выше факта является непосредственным из определения нормы и линейности \mathbb{E}

Свойство 3. называется **неравенством треугольника**, как и в векторном случае

Свойство 4. — это просто **неравенство Коши — Буняковского** для случайных величин со страницы ??

Как и в векторном случае, неравенство треугольника доказывается неравенством Коши - Буняковского (смотрите упражнение ??)

Относительно 1., $\|x\| = 0$ не подразумевает, что $x(\omega) = 0$ для всех $\omega \in \Omega$

Мы можем сказать, что если $\|x\| = 0$, то $\mathbb{P}\{x = 0\} = 1$

При работе с L_2 , принято соглашение не различать случайные величины, различающиеся с нулевой вероятностью.

Линейные подпространства в L_2

Любая **линейная комбинация** случайных величин с конечной дисперсией

$$\alpha_1 x_1 + \cdots + \alpha_K x_K, \quad \alpha_k \in \mathbb{R}, x_k \in L_2 \quad (8)$$

снова в L_2

Когда X — подпространство L_2 , множество конечных линейных комбинаций, которое может быть сформировано из элементов X , называется **линейной оболочкой** X , и обозначается как $\text{span } X$

Пример. Если $x \in L_2$ и $\mathbb{1} := \mathbb{1}_\Omega$ постоянная случайная переменная, всегда равная 1, то $\text{span}\{\mathbb{1}, x\}$ — множество случайных величин

$$\alpha + \beta x := \alpha \mathbb{1} + \beta x \quad \text{для скаляров } \alpha, \beta \quad (9)$$

Это множество \mathcal{L} введенное, когда мы обсуждали лучшие линейные предикторы

Подмножество S множества L_2 называется **линейным подпространством** L_2 , если оно замкнуто относительно сложения и умножения на скаляр

- для каждого $x, y \in S$ и $\alpha, \beta \in \mathbb{R}$, мы имеем $\alpha x + \beta y \in S$

Пример. Линейная оболочка любого множества элементов L_2 — линейное подпространство в L_2

Пример. Множество $Z := \{x \in L_2 : \mathbb{E}x = 0\}$ является линейным подпространством L_2 , так как

$$x, y \in Z \text{ и } \alpha, \beta \in \mathbb{R} \implies \mathbb{E}[\alpha x + \beta y] = \alpha \mathbb{E}[x] + \beta \mathbb{E}[y] = 0$$

Как и в \mathbb{R}^N , **ортонормированный базис** линейного подпространства S пространства L_2 — множество $\{u_1, \dots, u_K\} \subset S$ со свойством

$$\langle u_j, u_k \rangle = \mathbb{1}\{j = k\}$$

$$\text{и } \text{span}\{u_1, \dots, u_K\} = S$$

Пример. Пусть $x \in L_2$ такой, что $S := \text{span}\{\mathbb{1}, x\}$ множество случайных величин

$$\alpha + \beta x := \alpha \mathbb{1} + \beta x \quad \text{for scalars } \alpha, \beta \quad (10)$$

Если мы определим

$$u_1 := \mathbb{1} \quad \text{и} \quad u_2 := \frac{x - \mu}{\sigma_x}$$

Тогда

$$\langle u_1, u_2 \rangle = \mathbb{E}[u_1 u_2] = \mathbb{E}\left[\frac{x - \mu}{\sigma_x}\right] = 0$$

Ясно, что $\|u_1\| = \|u_2\| = 1$, так что эта пара ортонормирована

Также просто показать, что $\text{span}\{u_1, u_2\} = \text{span}\{\mathbb{1}, x\}$, значит $\{u_1, u_2\}$ ортонормированный базис для S

Проекция в L_2

Как и в евклидовом случае, если $\langle x, y \rangle = 0$, мы говорим, что x и y **ортогональны**, и пишем $x \perp y$

Факт. Если $x, y \in L_2$ и $\mathbb{E}x = 0$ или $\mathbb{E}y = 0$, то $x \perp y \iff \text{cov}[x, y] = 0$

Возьмем $y \in L_2$ и линейное подпространство $S \subset L_2$, мы ищем ближайший элемент \hat{y} множества S к y

Близость по норме L_2 , так что \hat{y} решение минимизации $\|y - z\|$ для всех $z \in S$

Мы ищем

$$\hat{y} = \operatorname{argmin}_{z \in S} \|y - z\| = \operatorname{argmin}_{z \in S} \sqrt{\mathbb{E}[(y - z)^2]} \quad (11)$$

Следующая теорема имитирует теорему об ортогональной проекции, которую мы уже видели:

Теорема. (??) Пусть $y \in L_2$ и S — любое непустое замкнутое линейное подпространство L_2

Следующие утверждения верны:

1. задача оптимизации (11) имеет ровно одно решение
2. $\hat{y} \in L_2$ является единственным решением

Утверждение, что S замкнуто значит, что $\{x_n\} \subset S$ и $x \in L_2$ с $\|x_n - x\| \rightarrow 0$ подразумевает $x \in S$ — условие истинное для всех линейных подпространств, с которыми мы хотим работать

Аналогично в случае \mathbb{R}^N , случайная переменная \hat{y} выше называется **ортгональной проекцией y на S**

Возьмем фиксированное S , операция

$$y \mapsto \text{ортгональная проекция } y \text{ на } S$$

— функция из L_2 в L_2 :

- функция называется **ортгональной проекцией на S**
- функция обозначается как \mathbf{P}
- мы пишем $\mathbf{P} = \text{proj } S$

Для каждого $y \in L_2$, $\mathbf{P}y$ отображение y с помощью \mathbf{P} , которое является ортогональной проекцией \hat{y}

- интерпретируем $\mathbf{P}y$ как *лучший префиктор y из множества случайных величин, содержащегося в S*

Факт. (??)

Если S — любое линейное подпространство L_2 , и $\mathbf{P} = \text{proj } S$, то

1. \mathbf{P} — линейная функция.

Более того, для любых $y \in L_2$, получается

2. $\mathbf{P}y \in S$,
3. $y - \mathbf{P}y \perp S$,
4. $\|y\|^2 = \|\mathbf{P}y\|^2 + \|y - \mathbf{P}y\|^2$,
5. $\|\mathbf{P}y\| \leq \|y\|$, и
6. $\mathbf{P}y = y$ тогда и только тогда, когда $y \in S$.

В 1, \mathbf{P} линейна значит, что $\mathbf{P}(\alpha x + \beta y) = \alpha \mathbf{P}x + \beta \mathbf{P}y$ для всех $x, y \in L_2$ и $\alpha, \beta \in \mathbb{R}$

Факт. (??) Пусть S_i — линейное подпространство L_2 для $i = 1, 2$ и $\mathbf{P}_i = \text{proj } S_i$. Если $S_1 \subset S_2$, то $\mathbf{P}_1 \mathbf{P}_2 y = \mathbf{P}_1 y$ для всех $y \in L_2$

Факт. (??) Если $\{u_1, \dots, u_K\}$ — ортонормированный базис S , то для всех $y \in L_2$,

$$\mathbf{P}y = \sum_{k=1}^K \langle y, u_k \rangle u_k \quad (12)$$

Пример. (??) Среднее случайной переменной x можно рассматривать как 'лучший предиктор x среди множества констант'

Пусть $S := \text{span}\{\mathbb{1}\}$, где $\mathbb{1} := \mathbb{1}_\Omega$, и $\mathbf{P} := \text{proj } S$

Объект $\mathbf{P}x$ как раз лучший предиктор x в классе постоянных случайных величин

Не удивительно, что $\mathbf{P}x = \mu \mathbb{1}$, где $\mu := \mathbb{E} x$

Самый простой способ проверить это — заметить, что $\{\mathbb{1}\}$ является ортонормированным множеством, охватывающим S , и следовательно, по (12),

$$\mathbf{P}x = \langle x, \mathbb{1} \rangle \mathbb{1} = \mathbb{E}[x\mathbb{1}]\mathbb{1} = \mathbb{E}[x]\mathbb{1} = \mu \mathbb{1}$$

Вы можете также проверить утверждение, что $\mu \mathbb{1}$ — проекция x на S , проверив условия в (ii) теоремы ??

Пример.

Зафиксируем $x, y \in L_2$ и рассмотрим проецирование y на $S := \text{span}\{\mathbb{1}, x\}$

Множество S является множеством случайных величин

$$\alpha + \beta x := \alpha \mathbb{1} + \beta x \quad \text{для скаляров } \alpha, \beta$$

Задача проецирования y на S эквивалентна задаче поиска лучшего линейного предиктора из $\S??$

Для реализации отзыва проекции

$$u_1 := \mathbb{1} \quad \text{и} \quad u_2 := \frac{x - \mu}{\sigma_x}$$

сформируем ортонормированный базис для S

Пусть $\mathbf{P} = \text{proj } S$, применим факт (??), получаем

$$\mathbf{P}y = \langle y, u_1 \rangle u_1 + \langle y, u_2 \rangle u_2 = \mathbb{E}[y] + \frac{\text{cov}[x, y]}{\text{var}[x]}(x - \mathbb{E}[x])$$

Альтернативно

$$\mathbf{P}y = \alpha^* + \beta^* x$$

$$\text{где } \beta^* := \frac{\text{cov}[x, y]}{\text{var}[x]} \quad \text{и} \quad \alpha^* := \mathbb{E}[y] - \beta^* \mathbb{E}[x]$$

Регрессия населения

Рассмотрим расширение задачи поиска лучшего линейного предиктора, описанной выше, до задачи, в которой информация для прогнозирования y — случайный вектор \mathbf{x} в \mathbb{R}^K

Мы ищем L_2 ортогональную проекцию y на линейное подпространство:

$\text{span}\{\mathbf{x}\} :=$ случайные величины вида $\mathbf{x}^T \mathbf{b}$ для некоторых $\mathbf{b} \in \mathbb{R}^K$

Предположим, что $\mathbb{E}[\mathbf{x}^T \mathbf{x}] < \infty$

Факт. (??) Если $\mathbb{E}[\mathbf{x}\mathbf{x}^\top]$ положительно определена, то проекция $\mathbf{P}y$ любого $y \in L_2$ на $\text{span}\{\mathbf{x}\}$ определяется как

$$\hat{y} = \mathbf{x}^\top \mathbf{b}^* \quad \text{где} \quad \mathbf{b}^* := \mathbb{E}[\mathbf{x}\mathbf{x}^\top]^{-1} \mathbb{E}[\mathbf{x}y]$$

Упражнение ?? просит доказать вышеизложенный факт

Положительная определенность $\mathbb{E}[\mathbf{x}\mathbf{x}^\top]$ обеспечивает обратимость, значит \mathbf{b}^* однозначно определено

По определению ортогональных проекций, \mathbf{b}^* обязательно удовлетворяет

$$\mathbf{b}^* = \underset{\mathbf{a} \in \mathbb{R}^K}{\operatorname{argmin}} \mathbb{E}[(y - \mathbf{x}^\top \mathbf{a})^2]$$

Задача линейного прогнозирования рассматривается также под названием **линейная регрессия населения**

- "население", потому что мы используем истинное совместное распределение (x, y) , когда считаем ожидания

У регрессии популяции есть аналог, называемый многомерной линейной регрессией, основанный на наблюдениях (x, y) – мы обсудим это в главе ??

Измеримость

Мы не всегда хотим ограничиваться линейными прогнозами

Чтобы отказаться от требования линейности, изменим линейное подпространство, используемое для проецирования, из множества линейных функций x на множество произвольных функций x

В результате, лучший предиктор — это условное математическое ожидание относительно x

Подпространством произвольных действительных функций от \mathbf{x} называются \mathbf{x} -измеримые функции

Пусть $\mathcal{G} := \{x_1, \dots, x_D\}$ — любое множество случайных величин и z — любая другая случайная величина

Переменная z **\mathcal{G} -измерима**, если существует \mathcal{B} -измеримая функция $g: \mathbb{R}^D \rightarrow \mathbb{R}$, такая что

$$z = g(x_1, \dots, x_D)$$

- равенство между случайными величинами следует интерпретировать поточечно

\mathcal{G} иногда упоминается как **информационное множество**

Мы также будем писать $\mathbf{x} = (x_1, \dots, x_D)$ и говорить, что z является \mathbf{x} -измеримым

Аналогичная терминология будет использоваться для скаляров и матриц

- например, если \mathbf{X} — случайная матрица, то \mathbf{X} -измеримость означает \mathcal{G} -измеримость, когда \mathcal{G} содержит все элементы \mathbf{X}

Интуиция: \mathcal{G} -измеримость z значит, что z полностью определяется элементами в \mathcal{G}

Пример. Пусть x, y и z — случайные величины и пусть α и β — скаляры

Если $z = \alpha x + \beta y$, то z $\{x, y\}$ -измеримо (возьмем $g(s, t) := \alpha s + \beta t$)

Пример. Если x_1, \dots, x_N — случайные величины и $\mathcal{G} := \{x_1, \dots, x_N\}$, то выборочное среднее $\bar{x}_N := \frac{1}{N} \sum_{n=1}^N x_n$ является \mathcal{G} -измеримым.

Пример. Пусть x и y независимые и невырожденные

Тогда y не является x -измеримым. Если бы он таким являлся, мы бы имели $y = g(x)$ для некоторой функции g , противоречащее независимости x и y

Пример. Пусть $y = \alpha$, где α — константа

Эта вырожденная случайная величина является \mathcal{G} -измеримой для любых информационных множеств \mathcal{G} , потому что y уже детерминированный

Например, если $\mathcal{G} = \{x_1, \dots, x_p\}$, то мы можем взять $y = g(x_1, \dots, x_p) = \alpha + \sum_{i=1}^p 0x_i$

Факт. (??) Пусть α, β — любые scalars, и пусть x и y — случайные величины. Если x и y являются \mathcal{G} -измеримыми, то $u := xy$ и $v := \alpha x + \beta y$ также являются \mathcal{G} -измеримыми

Предположим, что $\mathcal{G} \subset L_2$ и рассмотрим множество

$$L_2(\mathcal{G}) := \{\text{все } \mathcal{G}\text{-измеримые случайные величины в } L_2\}$$

С учетом факта ??:

Факт. Для любых $\mathcal{G} \subset L_2$, множество $L_2(\mathcal{G})$ — линейное подпространство L_2

Это дает нам подпространство для проецирования, что позволяет нам определять условные математические ожидания

Факт. (??) Если $\mathcal{G} \subset \mathcal{H}$ и z является \mathcal{G} -измеримой, то z является \mathcal{H} -измеримой.

Если z известен, когда переменные в \mathcal{G} известны, то он точно известен, когда дополнительная информация, предоставленная \mathcal{H} , доступна

Пример. Пусть x_1 , x_2 и y — случайные величины и пусть

$$\mathcal{G} := \{x_1\} \subset \{x_1, x_2\} =: \mathcal{H}$$

Если y является \mathcal{G} -измеримой, то $y = g(x_1)$ для некоторых \mathcal{B} -измеримых g . Но тогда y будет также являться \mathcal{H} -измеримой. Например, мы можем написать $y = h(x_1, x_2)$, где $h(x_1, x_2) = g(x_1) + 0x_2$.

Факт. (5.2.12) Если $\mathcal{G} \subset \mathcal{H}$, то $L_2(\mathcal{G}) \subset L_2(\mathcal{H})$

Условное математическое ожидание

Пусть $\mathcal{G} \subset L_2$ и y — некоторая случайная величина L_2

Условное математическое ожидание y при данном \mathcal{G} записывается как $\mathbb{E}[y | \mathcal{G}]$ или $\mathbb{E}^{\mathcal{G}}[y]$ и определяется как

$$\mathbb{E}[y | \mathcal{G}] := \operatorname{argmin}_{z \in L_2(\mathcal{G})} \|y - z\| \quad (13)$$

$\mathbb{E}[y | \mathcal{G}]$ — лучший предиктор y при данной информации, содержащейся в \mathcal{G}

Решение такой задачи минимизации вообще существует? И является ли оно единственным?

- да и да

Имеется

$$\mathbb{E}[y | \mathcal{G}] = \mathbf{P}y \quad , \text{ когда } \mathbf{P} := \text{proj } L_2(\mathcal{G})$$

По теореме об ортогональной проекции, проекция существует и является единственной

Альтернативное (и эквивалентное) определение условного математического ожидания

Функция \hat{y} , где $\hat{y} \in L_2$, — **условное математическое ожидание** y при данном \mathcal{G} , если

1. \hat{y} является \mathcal{G} -измеримой и
2. $\mathbb{E}[\hat{y}z] = \mathbb{E}[yz]$ для всех \mathcal{G} -измеримых $z \in L_2$.

Для удобства мы также будем использовать такие символы, как $\mathbb{E}[y | x_1, \dots, x_D]$ или $\mathbb{E}[y | \mathbf{x}]$

- так же, как $\mathbb{E}[y | \mathcal{G}]$, когда \mathcal{G} определяется как информационное множество, содержащее переменные, на которые мы ставим условие

Пример. Если x и u независимые, $\mathbb{E}u = 0$ и $y = x + u$, то $\mathbb{E}[y | x] = x$. Чтобы доказать это, нам нужно показать, что x удовлетворяет условиям 1–2 выше

Ясно, что x является x -измеримой

Для 2. мы должны показать, что $\mathbb{E}[xz] = \mathbb{E}[yz]$ для всех x -измеримых z . Это означает утверждение

$$\mathbb{E}[xg(x)] = \mathbb{E}[(x + u)g(x)]$$

для любых \mathcal{B} -измеримых g , которое является верным из-за независимости и $\mathbb{E}u = 0$

Факт. (??) Возьмем $\mathbf{x} \in \mathbb{R}^D$ и y в L_2 , существует \mathcal{B} -измеримая функция $f^*: \mathbb{R}^D \rightarrow \mathbb{R}$, такая что $\mathbb{E}[y | \mathbf{x}] = f^*(\mathbf{x})$

Частная функция f^* , удовлетворяющая $f^*(\mathbf{x}) = \mathbb{E}[y | \mathbf{x}]$ называется **функцией регрессии** y при данном \mathbf{x}

Пример. Если x и y — случайные величины и $p(y | x)$ — условная функция плотности y при данном x , то

$$\mathbb{E}[y | x] = \int t p(t | x) dt$$

Докажите в качестве упражнения ?? в ЕТ

Факт. (??) Пусть x и y — случайные величины в L_2 , пусть α и β — скаляры, и пусть \mathcal{G} и \mathcal{H} — подмножества L_2 . Следующие свойства выполняются:

1. Линейность: $\mathbb{E}[\alpha x + \beta y \mid \mathcal{G}] = \alpha \mathbb{E}[x \mid \mathcal{G}] + \beta \mathbb{E}[y \mid \mathcal{G}]$
2. Если $\mathcal{G} \subset \mathcal{H}$, то $\mathbb{E}[\mathbb{E}[y \mid \mathcal{H}] \mid \mathcal{G}] = \mathbb{E}[y \mid \mathcal{G}]$ и $\mathbb{E}[\mathbb{E}[y \mid \mathcal{G}]] = \mathbb{E}[y]$ (**закон повторных ожиданий**)
3. Если y не зависит от переменных в \mathcal{G} , то $\mathbb{E}[y \mid \mathcal{G}] = \mathbb{E}[y]$.
4. Если y является \mathcal{G} -измеримой, то $\mathbb{E}[y \mid \mathcal{G}] = y$
5. Если x является \mathcal{G} -измеримой, то $\mathbb{E}[xy \mid \mathcal{G}] = x \mathbb{E}[y \mid \mathcal{G}]$ (**условный детерминизм**)

Резюмируем: при данном $y \in L_2$ и случайном векторе \mathbf{x} в \mathbb{R}^D , условное математическое ожидание $\mathbb{E}[y | \mathbf{x}]$ — функция f^* переменной \mathbf{x} , называемая функцией регрессии y при данном \mathbf{x} , такая что:

$$f^*(\mathbf{x}) = \operatorname{argmin}_{g \in G} \mathbb{E}[(y - g(\mathbf{x}))^2] \quad (14)$$

где G — множество функций из \mathbb{R}^D в \mathbb{R} с $g(\mathbf{x}) \in L_2$

Для любых $g \in G$, мы также имеем

$$\mathbb{E}[(y - g(\mathbf{x}))^2] = \mathbb{E}[(y - f^*(\mathbf{x}))^2] + \mathbb{E}[(f^*(\mathbf{x}) - g(\mathbf{x}))^2] \quad (15)$$

Это подразумевает, что (14), потому что $(f^*(\mathbf{x}) - g(\mathbf{x}))^2 \geq 0$

Чтобы доказать (15), пусть f^* — функция регрессии, возьмем любой $g \in G$ и заметим, что

$$\begin{aligned}(y - g(\mathbf{x}))^2 &= (y - f^*(\mathbf{x}) + f^*(\mathbf{x}) - g(\mathbf{x}))^2 \\&= (y - f^*(\mathbf{x}))^2 + 2(y - f^*(\mathbf{x}))(f^*(\mathbf{x}) - g(\mathbf{x})) \\&\quad + (f^*(\mathbf{x}) - g(\mathbf{x}))^2\end{aligned}$$

Рассмотрим математическое ожидание перемножения разных величин. Из закона повторных ожиданий:

$$\begin{aligned}\mathbb{E} \{ (y - f^*(\mathbf{x}))(f^*(\mathbf{x}) - g(\mathbf{x})) \} & \qquad (16) \\&= \mathbb{E} \{ \mathbb{E} [(y - f^*(\mathbf{x}))(f^*(\mathbf{x}) - g(\mathbf{x})) \mid \mathbf{x}] \}\end{aligned}$$

Используем условный детерминизм, перепишем часть в фигурных скобках справа как

$$(f^*(\mathbf{x}) - g(\mathbf{x}))\mathbb{E}[(y - f^*(\mathbf{x})) | \mathbf{x}]$$

Для второй части данного умножения

$$\mathbb{E}[y - f^*(\mathbf{x}) | \mathbf{x}] = \mathbb{E}[y | \mathbf{x}] - \mathbb{E}[f^*(\mathbf{x}) | \mathbf{x}] = \mathbb{E}[y | \mathbf{x}] - f^*(\mathbf{x}) = 0$$

Значит математическое ожидание в (16) равно нулю —
Уравнение (15) следует

Векторный случай

Возьмем случайные матрицы \mathbf{X} и \mathbf{Y}

$$\mathbb{E}[\mathbf{Y} | \mathbf{X}] := \begin{pmatrix} \mathbb{E}[y_{11} | \mathbf{X}] & \cdots & \mathbb{E}[y_{1K} | \mathbf{X}] \\ \vdots & & \vdots \\ \mathbb{E}[y_{N1} | \mathbf{X}] & \cdots & \mathbb{E}[y_{NK} | \mathbf{X}] \end{pmatrix}$$

Мы также определим

1. $\text{cov}[\mathbf{x}, \mathbf{y} | \mathbf{Z}] := \mathbb{E}[\mathbf{x}\mathbf{y}^T | \mathbf{Z}] - \mathbb{E}[\mathbf{x} | \mathbf{Z}]\mathbb{E}[\mathbf{y} | \mathbf{Z}]^T$
2. $\text{var}[\mathbf{x} | \mathbf{Z}] := \mathbb{E}[\mathbf{x}\mathbf{x}^T | \mathbf{Z}] - \mathbb{E}[\mathbf{x} | \mathbf{Z}]\mathbb{E}[\mathbf{x} | \mathbf{Z}]^T$

Свойства скалярных условных математических ожиданий в факте ?? переходят к случаю с матрицами

Неполный список:

Факт. (??) Если \mathbf{X} , \mathbf{Y} и \mathbf{Z} — случайные матрицы и \mathbf{A} и \mathbf{B} постоянные и согласованные, то

1. $\mathbb{E}[\mathbf{Y} | \mathbf{Z}]^T = \mathbb{E}[\mathbf{Y}^T | \mathbf{Z}]$.
2. $\mathbb{E}[\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y} | \mathbf{Z}] = \mathbf{A}\mathbb{E}[\mathbf{X} | \mathbf{Z}] + \mathbf{B}\mathbb{E}[\mathbf{Y} | \mathbf{Z}]$.
3. $\mathbb{E}[\mathbb{E}[\mathbf{Y} | \mathbf{X}]] = \mathbb{E}[\mathbf{Y}]$ и $\mathbb{E}[\mathbb{E}[\mathbf{Y} | \mathbf{X}, \mathbf{Z}] | \mathbf{X}] = \mathbb{E}[\mathbf{Y} | \mathbf{X}]$.
4. Если \mathbf{X} и \mathbf{Y} независимые, то $\mathbb{E}[\mathbf{Y} | \mathbf{X}] = \mathbb{E}[\mathbf{Y}]$.
5. Если $g(\mathbf{X})$ — матрица, зависящая только от \mathbf{X} , то
 - 5.1 $\mathbb{E}[g(\mathbf{X}) | \mathbf{X}] = g(\mathbf{X})$
 - 5.2 $\mathbb{E}[g(\mathbf{X}) \mathbf{Y} | \mathbf{X}] = g(\mathbf{X}) \mathbb{E}[\mathbf{Y} | \mathbf{X}]$ и
 $\mathbb{E}[\mathbf{Y} g(\mathbf{X}) | \mathbf{X}] = \mathbb{E}[\mathbf{Y} | \mathbf{X}] g(\mathbf{X})$